

経費精算プラットフォーム

PDF → Markdown / RHMD 変換精度検証レポート

文書ID: PDF-COMPLEX-001 版: 1.2 作成日: 2026-08-25 作成者: RTMD QA

目的
複雑な帳票レイアウト、自然な日本語、座標付きテキスト、表・画像を一つのPDFに集約し、変換後の構造と可読性を検証する。

判定基準
文字欠落なし / ページ順保持 / 表の行列順保持 /
ヘッダー・フッター混入を識別 / 画像参照を保持

1. 検証観点

入力レイアウト	変換で守る情報
- A4縦、固定ヘッダー/フッター、ページ番号 - 日本語と英数字・記号・長い識別子の混在 - 表のセル内改行、桁区切り、状態ラベル - 画像・キャプション・注釈の位置関係	- 見出しの階層と本文の段落境界 - 複数カラムの読み順（左→右、上→下） - 表のヘッダー、列数、行順 - 画像はasset参照または説明を伴う

2. システム構成とデータフロー

入力	抽出	正規化	出力
PDF-COMPLEX-001 日本語帳票 / 3ページ	PdfTextExtractor 座標・フォント・ActualText	DocumentGraph page partition / paragraph nodes	report.md report.rhmd + sidecar

処理上の注意: 同一ページ上のヘッダー・本文・脚注は座標のY値だけでは分離しにくい。変換結果ではページ境界コメントと原文の順序を照合する。

3. 月次KPIと承認状態

指標ID	指標名	目標値	実績	判定	備考
KPI-01	申請処理時間 p95	1.0秒以下	0.82秒	合格	添付転送時間を除外
KPI-02	月間申請件数	50,000件	42,680件	合格	2026年7月集計
KPI-03	差戻し率	8%未満	9.4%	要確認	部門別の偏りを調査
KPI-04	監査ログ欠落	0件	0件	合格	日次検査・改ざん検知
KPI-05	支払連携遅延	5分未満	3分12秒	合格	再送5回まで

承認フロー

状態	担当	遷移条件	SLA	エラー時の扱い
DRAFT	申請者	入力保存	なし	下書きとして保持
SUBMITTED	申請者	提出ボタン / 必須項目OK	即時	ProblemDetailsを返す
PENDING	承認者	承認キューへ登録	24時間	期限超過アラート
RETURNED	承認者	コメント付き差戻し	48時間	申請者へ通知
APPROVED	承認者	全承認条件OK	24時間	支払連携へ進む
ERROR	運用担当	retry_count >= 5	30分	DLQへ隔離・手動再送

4. 左右カラムの業務仕様

4.1 申請者向け • 領収書はPDF/JPEG/PNG、1ファイル10MB、合計50MBまで。 • 金額は税込・税抜を明示し、通貨コードはISO 4217を使用。 • 同一Idempotency-Keyの再送は同じclaim_idを返す。 4.2 API境界 • POST /v1/expense-claims は201 CreatedまたはRFC 7807形式のエラーを返す。 • Authorization: Bearer JWT、TLS 1.2以上、監査IDを必須化。	4.3 承認者向け • 承認・差戻しには理由を記録し、前後状態を監査ログへ追記する。 • 金額が100,000円を超える場合は二段階承認へ分岐。 • 代理承認は有効期限と委任元を明記する。 4.4 運用・障害対応 • 再送間隔は1/5/30/120/600秒、最大5回。 • DLQ滞留が100件を超えた場合は重大アラートを発報する。
--	---

5. 画像・注釈・測定結果




図1. 月別処理量の測定値。画像はPDF内に埋め込まれたPNGであり、変換後は画像assetとして参照可能であること。

注記A	画像の文字は本文テキストではなく、OCRを有効化した場合のみ派生テキストになる。
注記B	ページ下部の脚注は本文と混ぜず、位置情報を保って確認する。
注記C	マーカー PDF-COMPLEX-001 / END を抽出結果の完全性確認に使う。

6. 付録: 変換検証チェックリスト

No.	確認項目	期待結果	結果
01	文書IDと版数	PDF-COMPLEX-001 / 1.2 が保持される	PASS
02	日本語と英数字	文字化け・欠落がない	PASS
03	表の列数	6列KPI / 5列承認表を保持	PASS
04	複数カラム	左カラム→右カラムの順で読める	REVIEW
05	画像参照	図1のassetまたは注釈が残る	REVIEW
06	ヘッダー/フッター	ページ番号が本文ノードを汚染しない	REVIEW
07	終端マーカ	PDF-COMPLEX-001 / END が存在	PASS

再現情報

このPDFは tests/Rtmd.Tests/Fixtures/Pdf/generate_complex_pdf.py から生成する。フォントはリポジトリ同梱の NotoSansJP を使用し、日時・識別子・測定値は固定している。

PDF-COMPLEX-001 / END